01 / PROJECT OVERVIEW

근거를 확인하고, 답변을 검토하다

SupportPilot

RTX 5080에서 실행하는 sLLM 고객지원 시스템

정책 검색과 답변 가능성 판정, 원문 근거 검증을 연결하고 상담원이 초안을 수정·승인하는 작업실을 구현했습니다. 모델 학습부터 서빙 성능 비교와 API 회귀 평가까지 수행한 개인 AI 개발 프로젝트입니다.

LOCAL MODEL	GPU	PRODUCT
Qwen3 4B	**RTX 5080**	**상담 작업실**

해결하려는 문제

LLM이 정책에 없는 가격·기능을 추측하거나, 사용자가 요구한 잘못된 수치를 그대로 답하는 문제를 줄입니다. 환불처럼 사용자 사실 확인이 필요한 결정은 구조화된 규칙과 상담원 검토로 처리합니다.

담당 범위와 구현 결과

기획 및 정책 데이터 설계 → FastAPI·검색·모델 연동 → 환불 규칙·근거 검증 → 평가기와 실험 기록 → vLLM 최적화 → 상담 UI·SQLite 검토 이력 → QLoRA 학습 및 비교.

기술 선택: 테스트한 작은 질문군에서는 기본 모델과 어댑터가 같은 품질을 보였고 기본 모델의 추론 시간이 짧았습니다. 서비스에는 기본 모델을 선택하고 QLoRA는 비교 실험으로 보존했습니다.

대상 직무: AI 개발 / 개발 경험: 약 4년. 본 문서의 측정값은 사용자 WSL 실행 보고에 근거합니다. 최신 API 회귀의 전체 통과는 사용자 확인이며 상세 최신 보고서는 문서 작성 시 수집하지 않았습니다.

02 / SYSTEM DESIGN

모델과 규칙을 연결한 처리 구조

01 입력 질문과 선택적 환불 정보(plan, payment_date, usage_history)를 검증합니다.

02 검색 BM25 + multilingual-e5-small 임베딩을 RRF로 결합합니다. 근거가 없으면 답변을 보류합니다.

03 판정 Qwen이 질문에 직접 답할 정책과 추가 정보 필요 여부를 JSON으로 판정합니다.

04 근거 검증 별도 모델 요청에서 원문 구간 ID를 선택하고, 실제 인용문은 코드가 원문에서 복사합니다.

05 초안 생성 근거 기반 답변을 생성한 뒤 스키마, 정책 ID, 인용문의 원문 포함 여부를 검사합니다.

06 상담원 검토 원본 초안과 수정 답변을 보존하고 승인·반려 및 검토 시각을 SQLite에 기록합니다.

환불 요청은 구조화된 분기로 처리

연간 요금제 + 결제일 기준 0~7일 + 사용 이력 없음일 때 환불 대상 초안을 반환합니다. 정보 누락은 needs_information, 그 외 조건은 requires_review입니다. 사용자 입력은 검증되지 않은 사실로 표시하며 실제 환불은 수행하지 않습니다.

스택: Python 3.12 / FastAPI / Pydantic / Transformers / vLLM / sentence-transformers / SQLite / HTML·CSS·JavaScript. 배포 대상은 WSL의 로컬 데모 환경입니다.

03 / QLORA & QUALITY EVALUATION

학습을 실행하고, 채택 여부를 비교하다

작은 데이터로 학습 파이프라인부터 검증

160개 후보에서 10개 질문군을 검수했습니다. 질문 변형과 두 태스크를 같은 그룹에 유지하여 train 48 / validation 16 / test 16 레코드로 분할했습니다. 학습 대상은 답변 가능성 및 직접 근거 판정의 JSON이며, 입력은 loss에서 제외했습니다.

학습 설정	실행 결과
NF4 4비트 + BF16 / LoRA r=8, alpha=16	3 epochs / 18 optimizer steps
배치 1 / 누적 8 / 학습률 1e-4	train loss 0.1204 / validation loss 0.1963
gradient checkpointing / SDPA	로딩 포함 83.416초
PyTorch 메모리 측정	할당 최고 5.83 GiB / 예약 최고 7.133 GiB

고정 설정으로 보류한 test 평가

지표	기본 모델	QLoRA 어댑터
전체 검사 통과	16/16	16/16
스키마 준수	16/16	16/16
정답 근거 ID 일치	8/8	8/8
추론 P50	502ms	899ms
추론 P95	1,066ms	2,162ms

결정: 이 실험에서 어댑터의 추가 품질 이득은 관찰되지 않았습니다. 기본 모델을 서비스 후보로 선택했습니다. 비교는 동일 NF4 base에서 어댑터 활성·비활성으로 수행했습니다.

test 16개는 영수증 발급과 Pro API 한도 두 질문군의 변형입니다. 독립 질문 16개나 일반 정확도 100%로 해석하지 않습니다. validation은 체크포인트·프롬프트 선택에 사용했습니다. loss는 답변 정확도를 의미하지 않습니다.

04 / PERFORMANCE ENGINEERING

서빙 변경으로 동시 요청 처리 개선

v2.3 기준에서 Transformers 서버와 vLLM을 같은 3개 질문 혼합으로 비교했습니다. 각 동시성에 24건, backend 별 총 72건을 실행했고 내부 요청 오류는 0건이었습니다.

동시성	Transformers P95	vLLM P95	처리량 T / V
1	4.349초	1.634초	0.365 / 0.917건·초
2	7.545초	1.749초	0.388 / 1.676건·초
4	14.485초	1.963초	0.381 / 2.993건·초

동시성 4에서 관찰한 변화



처리량 약 7.86배 / P95 약 86.4% 감소. 측정된 반복 질문 부하에서의 결과이며 새로운 질문의 성능 보장은 아닙니다.

최적화 및 환경 분리

vLLM BF16, context 4096, max_num_seqs=4, GPU memory utilization=0.80, prefix caching을 설정했습니다. 검색·모델 워밍업과 단계별 시간 기록을 추가했습니다. API / vLLM / 학습 환경을 각각 분리했습니다.

Blackwell 환경에서 FlashInfer sampler의 JIT 의존성 문제를 확인하고 native sampler로 실행했습니다. 평가 모델 commit을 지정하고, 데이터 SHA와 어댑터 SHA 및 test 프로토콜을 기록하도록 구현했습니다.

비교 한계: 반복 질문과 prefix cache, 서로 다른 라이브러리·CUDA 런타임이 결과에 영향을 줍니다. 서빙 엔진 하나만의 인과 효과로 해석하지 않습니다. API 전체 지연이며 TTFT와 token throughput은 해당 실험에서 측정하지 않았습니다. 이 결과는 최신 v2.6의 부하 재측정값이 아닙니다.

05 / COUNSELOR WORKSPACE

초안부터 승인 이력까지 제품으로 구현



실제 로컬 UI 검증 화면의 답변 검토 영역

검토 흐름

질문 → 초안

고객 문의와 환불 정보를 입력하면 답변·근거·판정 결과를 표시합니다.

초안 → 수정

모델 원본을 보존하면서 상담원이 최종 답변을 편집합니다.

수정 → 승인·반려

검토자 이름과 결정·시각을 기록합니다. 이미 검토한 사례의 중복 처리는 차단합니다.

이력 → 재확인

최근 문의 목록과 상세 기록을 저장하고 새로고침 후 다시 확인할 수 있습니다.

검증한 동작

실제 WSL UI에서 문의 생성, 초안 수정, 승인, 새로고침 후 저장된 승인 이력 재확인을 수행했습니다. 화면은 당시 승인 완료 사례입니다.

승인은 로컬 기록입니다. 고객 메시지 전송이나 실제 환불 실행은 연결하지 않았습니다. 검토자 이름은 수동 입력이며 인증 기능은 구현 범위 밖입니다.

API와 데이터 보존

POST /api/questions: 평가용 응답 / POST·GET /api/cases: 문의 생성·조회 / POST /api/cases/{id}/review: 검토 기록 / GET /health: 구성·워밍업·프롬프트 버전.

SQLite 트랜잭션과 고유 검토 제약으로 중복 승인을 막습니다. DOM textContent로 사용자 데이터를 표시하고 원본 초안·수정 답변을 분리 보존합니다. 서버 재시작 후 UI 검증은 별도로 수행하지 않았습니다.

06 / DECISIONS & EVIDENCE

결과를 남기고, 한계를 설명하는 프로젝트

실험에서 배운 점과 수정 이력

관찰한 문제	대응과 판단
환불 불가를 정책보다 강하게 단정	사용자 사실·정책 규칙·상담원 확인을 분리
필요 이상의 원문 ID를 요구한 정답 라벨	원본을 보존하고 보정 이유·재채점 결과 기록
false 응답의 빈 필드 때문에 평가 실패	일관된 빈 필드 형식을 허용하고 모순 응답은 차단
정책 수정 지시를 정책 부재로 오판	검증된 v2.3 판정 프롬프트를 복원하고 가격 근거 규칙 추가
QLoRA가 기본 모델보다 느리고 품질 차이 없음	추가 품질 이득 미관찰로 기본 모델 선택

최신 서비스 상태와 증거 수준

API 프롬프트는 answerability-2.6-restored입니다. 사용자가 development·validation·final 회귀 전부 통과를 확인했습니다. 최신 상세 보고서와 지연 값은 본 문서에 포함하지 않았습니다. 기존 final 세트는 반복 개선에 사용했으므로 독립 최종 평가가 아닌 회귀 세트입니다.

로컬 단위 검증 41개는 mock 및 규칙 검사입니다. 실제 WSL GPU 실행 결과는 사용자가 제공한 학습·비교·API 보고에 근거합니다. QLoRA test 16/16은 explicit-v3 + NF4 결과이며 새 API 프롬프트 + vLLM BF16의 독립 성능으로 재사용하지 않습니다.

재현 자료와 다음 확장

코드와 정책·질문 데이터, 그룹 검수 기록, split manifest, 학습 run_config·metrics·adapter, 비교 JSON, test_protocol, API 회귀 JSON 및 v2.3 source ZIP을 보존하는 구조를 만들었습니다. 모델 commit: cdbee75f17c01a7cc42f958dc650907174af0554.

다음 확장은 새로운 질문군을 통한 독립 평가, 실제 서비스 프롬프트에서 어댑터 비교, 승인 권한 인증, 운영 모니터링 및 재현 가능한 배포입니다. 추가 데이터 규모나 미구현 기능을 완료 실적으로 표시하지 않습니다.

자료 위치: docs/EXPERIMENT_RESULTS.md, docs/QLORA_COMPARISON.md, docs/API_INTEGRATION_V24.md, reports/baselines/, reports/ui/approved-case.jpg. API 최신 통과는 사용자 확인. 공개 저장소 URL·작성자명·연락처는 제공되지 않아 문서에 임의로 기입하지 않았습니다.